

第三章 函数逼近

$$i = 2, 3, \dots, n$$

$$Ax = b$$

3.1 赋范线性空间与函数逼近问题

$$\left| E_r^*(y^*) \right| \leq \left| \frac{x_1^*}{y^*} \left(\frac{\partial f}{\partial x_1} \right)^* \right| \cdot \varepsilon_{r1}^* + \left| \frac{x_2^*}{y^*} \left(\frac{\partial f}{\partial x_2} \right)^* \right| \cdot \varepsilon_{r2}^*$$

$$E_r^*(x^*) = \frac{E(x^*)}{x^*} = \frac{x^* - x}{x^*}$$

- 本章重点探讨在线性空间上求一个函数，使之能最佳逼近未知函数的问题。为此首先引入赋范线性空间。

定义 设 $\|\cdot\|$ 为定义于线性空间 V 上的实值函数（泛函），满足（非负性、齐次性、三角不等式）：

1. $\|g\| \geq 0, \forall g \in V$ ，当且仅当 $g = 0$ 时有 $\|g\| = 0$

2. $\|rg\| = |r|\|g\|, \forall r \in R, g \in V$

3. $\|f + g\| \leq \|f\| + \|g\|, \forall f, g \in V$

则称函数 $\|\cdot\|$ 是线性空间 V 上的范数，称 V 为赋范线性空间。

例如 $[a,b]$ 上的连续函数的集合 $C[a,b]$ 是一线性空间，在该空间上定义实值函数 $\|\cdot\|_\infty$ 如下

$$\|f\|_\infty = \max_{a \leq x \leq b} |f(x)|, \forall f \in C[a,b]$$

则可以证明该实值函数是线性空间 $C[a,b]$ 上的一个范数，从而 $C[a,b]$ 关于该范数成为一个赋范线性空间。

在同一线性空间上可以定义不同的范数，得到不同的赋范空间。

- 又如，在 $C[a,b]$ 上可定义另一范数 $\| \cdot \|_2$ 如下

$$\|f\|_2 = \left(\int_a^b f^2(x) dx \right)^{\frac{1}{2}}, \forall f \in C[a,b]$$

- 对赋范线性空间 $(V, \| \cdot \|)$ 上的任意两个元素 f 和 g ，定义它们之间的距离如下

$$d(f, g) = \|f - g\|, \forall f, g \in V$$

- 于是, $(C[a,b], \|\cdot\|_\infty)$ 上的距离为

$$d(f, g) = \|f - g\|_\infty = \max_{a \leq x \leq b} |f(x) - g(x)|, \forall f, g \in C[a, b]$$

- $(C[a,b], \|\cdot\|_2)$ 上的距离为

$$d(f, g) = \|f - g\|_2 = \left(\int_a^b (f(x) - g(x))^2 dx \right)^{\frac{1}{2}}, \forall f, g \in C[a, b]$$

- 函数逼近问题：设 Φ 为一赋范空间，求 $\varphi^*(x) \in \Phi$ ，使得

$$\|f - \varphi^*\| = \min_{\varphi \in \Phi} \|f - \varphi\|$$

- 特别地，当 Φ 为有限维空间时，若 $\{\varphi_i\}_{i=0}^n$ 是它的一组基，则逼近问题为

求 $c_0^*, c_1^*, \dots, c_n^*$ ，使得

$$\left\| f - \sum_{i=0}^n c_i^* \varphi_i \right\| = \min_{c_i \in R} \left\| f - \sum_{i=0}^n c_i \varphi_i \right\|$$

当范数是 $\|\cdot\|_\infty$ 或 $\|\cdot\|_2$ 时，称逼近问题分别为最佳一致或最佳平方逼近问题。

3.2 内积空间与正交多项式

- 为讨论在多项式正交基下的函数逼近，首先定义内积空间。
- 定义 设 V 为一线性空间，若定义 $V \times V$ 上的二元实值函数 $(\cdot, \cdot)$ ，对任意 $f, g, h \in V$ 满足（对称性、线性性、非负性）
 1. $(f, g) = (g, f)$
 2. $(r_1 f + r_2 h, g) = r_1 (f, g) + r_2 (h, g), \forall r_1, r_2 \in R$
 3. $(f, f) \geq 0$; 当且仅当 $f=0$ 时有 $(f, f) = 0$
 则称实值函数 $(\cdot, \cdot)$ 是线性空间 V 上的一种内积，称 V 为关于 $(\cdot, \cdot)$ 的内积空间

- 例如，在线性空间 $C[a,b]$ 上定义实值函数

$$(f, g) = \int_a^b f(x)g(x)dx$$

可以验证该实值函数是 $C[a,b]$ 上的一个内积，从而使得 $C[a,b]$ 成为一内积空间。

另外，还可定义 $C[a,b]$ 上的内积为

$$(f, g)_\rho = \int_a^b f(x)g(x)\rho(x)dx$$

其中 $\rho(x)$ 权函数，满足条件

$$1. \rho(x) \geq 0; 2. \int_a^b \rho(x)dx > 0$$

$$3. \int_a^b x^k \rho(x)dx (k = 0, 1, \dots) \text{存在}$$

定义 $\|\alpha\| = (\alpha, \alpha)^{\frac{1}{2}}$

容易验证 $\|\alpha\|$ 为一范数，通常称为由内积诱导出的范数。

定理 设 $\varphi_0, \varphi_1, \dots, \varphi_n$ 为内积空间 Φ 中的元素，则 $\varphi_0, \varphi_1, \dots, \varphi_n$ 线性无关的充分必要条件是

Gram矩阵
$$G_n = \begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix}$$

非奇异，即 $\det(G_n) \neq 0$


定理 线性无关的 $\varphi_0, \varphi_1, \dots, \varphi_n$ 确定的Gram矩阵是实对称正定矩阵

- 线性空间上最常用的基是正交基或标准正交基，为此引入正交多项式系。
- 定义 内积空间V上的两个元素f和g，如果有 $(f,g)=0$ ，则称f,g正交；若V上的元素系 $\{f_i\}_{i=0}^{\infty}$ 满足两两正交，即对任意的非负整数i,j有

$$\begin{cases} (f_i, f_j) = 0 & (i \neq j) \\ (f_i, f_i) = \gamma_i > 0 \end{cases}$$

则称 $\{f_i\}_{i=0}^{\infty}$ 为正交系，进一步若 $(f_i, f_i) = 1 (i = 0, 1, 2, \dots)$ 则称 $\{f_i\}_{i=0}^{\infty}$ 为标准正交系。

三角函数系 $1, \cos(x), \sin(x), \cos(2x), \sin(2x), \dots$ 在 $[-\pi, \pi]$ 上是带权 $\rho(x) = 1$ 的正交函数族。



当 $f_i(x) (i=0,1,2,\dots)$ 为 i 次多项式时,
称 $\{f_i\}_{i=0}^{\infty}$ 为正交多项式系。

正交多项式性质:

1. $\{f_i\}_{i=0}^{\infty}$ 线性无关;
2. $\forall p(x) \in P_n$ 有 $(p(x), f_k(x)) = 0 (k \geq n+1)$
其中 P_n 是不超过 n 次多项式全体构成的
内积空间;
3. 正交多项式系 $\{f_i\}_{i=0}^{\infty}$ 中的 $f_n(x) (n \neq 0)$ 在区间
(a,b) 内有 n 个互不相同的实单零点;

4.正交多项式系 $\{f_i\}_{i=0}^{\infty}$ 中任何相邻三项之间有如下递推关系:

$$f_{k+1}(x) = (a_k x + b_k) f_k(x) + c_{k-1} f_{k-1}(x) (k = 1, 2, \dots)$$

其中

$$a_k = \frac{A_{k+1}^{(1)}}{A_k^{(1)}}, \quad b_k = \frac{A_{k+1}^{(1)}}{A_k^{(1)}} \left[\frac{A_{k+1}^{(2)}}{A_{k+1}^{(1)}} - \frac{A_k^{(2)}}{A_k^{(1)}} \right]$$

$$c_{k-1} = -\frac{a_k \gamma_k}{a_{k-1} \gamma_{k-1}} = -\frac{A_{k+1}^{(1)} A_{k-1}^{(1)} \gamma_k}{(A_k^{(1)})^2 \gamma_{k-1}}, \quad \gamma_k = (f_k, f_k) \neq 0$$

$A_m^{(1)}, A_m^{(2)}$ 分别为 $f_m(x)$ ($m = k-1, k, k+1$) 的首项和次项系数。

3.2.3 常用的正交多项式系

下面给出几种常用的正交多项式.

(1)Legendre多项式.

Legendre多项式可由三项递推公式

$$\begin{cases} P_0(x)=1, P_1(x)=x, \\ (n+1)P_{n+1}(x)=(2n+1)xP_n(x)-nP_{n-1}(x), k=1,2,\cdots, \end{cases}$$

给出.它们是在区间 $[-1,1]$ 上的带权 $\rho(x)=1$ 的正交多项式.前几个Legendre多项式如下:


$$P_2(x)=\frac{1}{2}(3x^2-1),$$

$$P_3(x)=\frac{1}{2}(5x^3-3x),$$

$$P_4(x)=\frac{1}{8}(35x^4-30x^2+3),$$

$$P_5(x)=\frac{1}{8}(63x^5-70x^3+15x).$$

它们的根都是在开区间 $(-1, 1)$ 上的单根,并且与原点对称.



(2)第一类Chebyshev多项式.

第一类Chebyshev多项式可由三项递推公式

$$\begin{cases} T_0(x) = 1, T_1(x) = x, \\ T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x), k = 1, 2, \dots, \end{cases}$$


给出.它们是在区间 $[-1,1]$ 上的带权 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ 的正交多项式.
前几个第一类Chebyshev多项式如下:

$$T_2(x) = 2x^2 - 1,$$

$$T_3(x) = 4x^3 - 3x,$$

$$T_4(x) = 8x^4 - 8x^2 + 1,$$

$$T_5(x) = 16x^5 - 20x^3 + 5x.$$



它们的根都是在开区间 $(-1, 1)$ 上的单根,并且与原点对称.

(3) Laguerre多项式系

Laguerre多项式可由三项递推公式

$$\begin{cases} L_0(x) = 1, L_1(x) = 1 - x, \\ L_{n+1}(x) = (1 + 2n - x)L_n(x) - n^2 L_{n-1}(x), n = 1, 2, \dots, \end{cases}$$

给出。它们是在区间 $[0, +\infty)$ 上带权 $\rho(x) = e^{-x}$ 的正交多项式。
前几个Laguerre多项式如下:


$$L_2(x) = x^2 - 4x + 2,$$

$$L_3(x) = -x^3 + 9x^2 - 18x + 6,$$

$$L_4(x) = x^4 - 16x^3 + 72x^2 - 96x + 24$$

$$L_5(x) = -x^5 + 25x^4 - 200x^3 + 600x^2 - 600x + 120$$

它们的根都是在区间 $(0, +\infty)$ 上的单根。



(4) Hermite 多项式

Hermite多项式可由三项递推公式

$$\begin{cases} H_0(x) = 1, H_1(x) = 2x, \\ H_{n+1}(x) = 2xH_n(x) - 2nH_{n-1}(x), n = 1, 2, \dots \end{cases} \quad (2.4.10)$$

给出。它们是在区间 $(-\infty, +\infty)$ 上带权 $p(x) = e^{-x^2}$ 的正交多项式。前几个Hermite多项式如下：


$$H_2(x) = 4x^2 - 2,$$

$$H_3(x) = 8x^3 - 12x,$$

$$H_4(x) = 16x^4 - 48x^2 + 12,$$

$$H_5(x) = 32x^5 - 160x^3 + 120x.$$

它们的根都在区间 $(-\infty, +\infty)$ 上的单根，并且与原点对称



$$Ax = b$$

3.3最佳平方逼近

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

$$x_i = \frac{b_i - \sum_{j=1}^{i-1} l_{ij} x_j}{l_{ii}}$$

$i = 2, 3, \dots, n$

3.3.1 最佳平方逼近问题的求解

连续函数空间 $C[a,b]$ 上定义了内积就形成了一个内积空间，对内积空间任一元素 $f(x) \in C[a,b]$ ，也可用线性无关的基表示。

下面我们先讨论在区间 $[a,b]$ 上一般的最佳平方逼近问题。设 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$ ，是 $C[a,b]$ 中的线性无关函数，记

$$\Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\} = \{\varphi(x) : \varphi(x) = \sum_{k=0}^n c_k \varphi_k(x), c_k \in R\}$$

对于 $f(x) \in C[a,b]$ ，若存在 $\varphi^*(x) \in \Phi$ ，使得

$$\|f - \varphi^*\|_2^2 = \min_{\varphi \in \Phi} \int_a^b \rho(x) [f(x) - \varphi(x)]^2 dx,$$

则称 $\varphi^*(x)$ 是 $f(x)$ 在 $\Phi \subset C[a,b]$ 中的最佳平方逼近函数。

求 $\varphi^*(x)$ 等价于求多元函数

$$I(c_0, c_1, \dots, c_n) = \int_a^b \rho(x) \left[\sum_{k=0}^n c_k \varphi_k(x) - f(x) \right]^2 dx$$

的极小值。利用多元函数求极小值的必要条件有

$$\frac{\partial I}{\partial c_j} = 2 \int_a^b \rho(x) \left[\sum_{k=0}^n c_k \varphi_k(x) - f(x) \right] \varphi_j(x) dx = 0, j = 0, 1, \dots, n.$$

按内积的定义，上式可写为

$$\sum_{k=0}^n c_k (\varphi_k, \varphi_j) = (f, \varphi_j), j = 0, 1, \dots, n$$

这是关于 $c_k (k=0, 1, \dots, n)$ 的线性方程组，称为**法方程或正规方程组**。

$$c_0(\varphi_0, \varphi_j) + c_1(\varphi_1, \varphi_j) + \dots + c_n(\varphi_n, \varphi_j) = (f, \varphi_j)$$

$$j = 0, 1, \dots, n$$

矩阵形式(法方程组)为

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_1, \varphi_0) & \cdots & (\varphi_n, \varphi_0) \\ (\varphi_0, \varphi_1) & (\varphi_1, \varphi_1) & \cdots & (\varphi_n, \varphi_1) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_0, \varphi_n) & (\varphi_1, \varphi_n) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{pmatrix}$$

由于 $\varphi_0, \varphi_1, \dots, \varphi_n$ 线性无关, 故法方程的系数矩阵非奇异,

于是方程组有唯一解 $c_k = c_k^*, k = 0, 1, \dots, n$ 。从而得到

$$\varphi^*(x) = c_0^* \varphi_0(x) + c_1^* \varphi_1(x) + \dots + c_n^* \varphi_n(x).$$

即对任意 $\varphi(x) \in \Phi$, 有 $\|f - \varphi^*\|_2 \leq \|f - \varphi\|_2$.

事实上, 有 $(\sum_{k=0}^n c_k^* \varphi_k - f, \varphi_j) = 0, j = 0, 1, \dots, n$.

因此, 对任意 $\varphi(x) \in \Phi$, 有 $(\varphi^* - f, \varphi) = 0$, 从而也有 $(f - \varphi^*, \varphi^* - \varphi) = 0$

于是

$$\begin{aligned}\|f - \varphi\|_2^2 &= \|f - \varphi^* + \varphi^* - \varphi\|_2^2 = \|f - \varphi^*\|_2^2 + 2(f - \varphi^*, \varphi^* - \varphi) + \|\varphi^* - \varphi\|_2^2 \\ \|f - \varphi\|_2^2 &\geq \|f - \varphi^*\|_2^2.\end{aligned}$$

这就证明了结论，从而也证明了 f 在 Φ 中的最佳平方逼近的存在唯一性。

称最佳逼近的**误差**

$$\begin{aligned}\|\delta\|_2^2 &= (f - \varphi^*, f - \varphi^*) = (f, f) - (\varphi^*, f) \\ &= \|f\|_2^2 - \sum_{k=0}^n c_k^*(\varphi_k, f)\end{aligned}$$

为**平方误差**。

考虑特殊情形，设 $[a, b] = [0, 1]$, $\varphi_k(x) = x^k, k = 0, 1, \dots, n, \rho(x) = 1$ 。对于 $f \in C[a, b]$, 在 $\Phi = \text{span}\{1, x, \dots, x^n\}$ 中**最佳平方逼近多项式**可以表示为

$$p_n^*(x) = c_0^* + c_1^* x + \cdots + c_n^* x^n,$$

相应于法方程中的系数矩阵为

$$H_{n+1} = \begin{bmatrix} 1 & 1/2 & \cdots & 1/(n+1) \\ 1/2 & 1/3 & \cdots & 1/(n+2) \\ \vdots & \vdots & & \vdots \\ 1/(n+1) & 1/(n+2) & \cdots & 1/(2n+1) \end{bmatrix}$$

称之为**Hilbert**矩阵

例1 设 $f(x) = \sqrt{1+x^2}$ ，求 $[0, 1]$ 上的一次最佳平方逼近多项式。

解 由于

$$\varphi_0(x) = 1, \varphi_1(x) = x,$$

$$(f, \varphi_0) = \int_0^1 \sqrt{1+x^2} dx = \frac{1}{2} \ln(1+\sqrt{2}) + \frac{\sqrt{2}}{2} \approx 1.147$$

$$(f, \varphi_1) = \int_0^1 x\sqrt{1+x^2} dx = \frac{1}{3} (2\sqrt{2} - 1) \approx 0.609$$

得方程组

$$\begin{pmatrix} 1 & 1/2 \\ 1/2 & 1/3 \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \end{pmatrix} = \begin{pmatrix} 1.147 \\ 0.609 \end{pmatrix}$$

解得 $c_0=0.934, c_1=0.426$ 。从而最佳平方逼近为

$$p_1^*(x) = 0.934 + 0.426x$$

平方误差

$$\|\delta\|_2^2 = \int_0^1 (1+x^2)dx - 0.934(f, \varphi_0) - 0.426(f, \varphi_1) = 0.0026$$

由于Hilbert矩阵是病态的（见第5章），用 $\{1, x, \dots, x^n\}$ 作基时，求法方程的解，舍入误差很大。实用的办法是采用正交多项式作基。

基于正交基函数的最佳平方逼近

若 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$ 是正交多项式组, 则法方程系数矩阵为

$$\begin{pmatrix} (\varphi_0, \varphi_0) & 0 & \dots & 0 \\ 0 & (\varphi_1, \varphi_1) & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & (\varphi_n, \varphi_n) \end{pmatrix}$$

从而

$$c_k^* = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)}, k = 0, 1, \dots, n$$

于是 $f(x)$ 的最佳平方逼近多项式为

$$\varphi^*(x) = \sum_{k=0}^n \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} \varphi_k(x)$$

例2 设 $f(x)=e^x$, 在 $[-1,1]$ 上用勒让德多项式作 f 的三次多次最佳平方逼近多项式。

解 用勒让德多项式 $P_k(x)$ ($k=0,1,2,3$), 可得

$$(f, P_0) = \int_{-1}^1 e^x dx \approx 2.3504, \quad (f, P_1) = \int_{-1}^1 x e^x dx \approx 0.7358$$

$$(f, P_2) = \int_{-1}^1 \frac{1}{2} (3x-1) e^x dx \approx 0.1431,$$

$$(f, P_3) = \int_{-1}^1 \frac{1}{2} (5x^2 - 3x) e^x dx \approx 0.02013,$$

$$c_0^* = (f, P_0)/(P_0, P_0) = 1.1752, \quad c_1^* = (f, P_1)/(P_1, P_1) = 1.0136,$$

$$c_2^* = (f, P_2)/(P_2, P_2) = 0.3578, \quad c_3^* = (f, P_3)/(P_3, P_3) = 0.07046,$$

于是最佳平方逼近为

$$\varphi^*(x) = 0.9963 + 0.9979x + 0.5367x^2 + 0.1761x^3 \quad .$$

平方误差

$$\|\delta\|_2^2 = \int_{-1}^1 e^{2x} dx - \sum_{k=0}^3 (c_k^*)^2 (\varphi_k, \varphi_k) = 0.0007$$

3.4 曲线拟合的最小二乘方法

曲线拟合模型及其求解


实例：考察某种纤维的强度与其拉伸倍数的关系,下表是实际测定的24个纤维样品的强度与相应的拉伸倍数是记录:

编 号	拉伸倍数 x_i	强 度 y_i	编 号	拉伸倍数 x_i	强 度 y_i
1	1.9	1.4	13	5	5.5
2	2	1.3	14	5.2	5
3	2.1	1.8	15	6	5.5
4	2.5	2.5	16	6.3	6.4
5	2.7	2.8	17	6.5	6
6	2.7	2.5	18	7.1	5.3
7	3.5	3	19	8	6.5
8	3.5	2.7	20	8	7
9	4	4	21	8.9	8.5
10	4	3.5	22	9	8
11	4.5	4.2	23	9.5	8.1
12	4.6	3.5	24	10	8.1

纤维强度随拉伸
倍数增加而增加

并且24个点大致分
布在一条直线附近

因此可以认为强度
 y 与拉伸倍数 x 的主
要关系应是线性关
系



$$y(x) = \beta_0 + \beta_1 x$$

----- (1)

其中 β_0, β_1 为待定参数

我们希望 $y(x) = \beta_0 + \beta_1 x$ 与所有的数据点(样本点) (x_i, y_i)
越接近越好

必须找到一种度量标准来衡量什么曲线最接近所有数据点

一、最小二乘法的基本概念

令 $\delta_i = y(x_i) - y_i$

在回归分析中称为残差

一般使用

$$\|\delta\|_2^2 = \sum_{i=0}^m \delta_i^2 = \sum_{i=0}^m (y(x_i) - y_i)^2$$

作为衡量 $y(x)$ 与数据点 (x_i, y_i) 偏离程度大小的度量标准

称为平方误差

从而确定(1)中的待定系数

$$\|\delta\|_2^2 = \sum_{i=0}^m \delta_i^2 = \sum_{i=0}^m (y(x_i) - y_i)^2$$

在回归分析中称为残差平方和

注意(1)式是一条直线

但 x, y 的关系并不一定是线性关系

因此将问题一般化

设 $(x_i, y_i)(i = 0, 1, \dots, m)$ 为给定的一组数据

设 x, y 的关系为 $y = S(x)$

其中 $S(x)$ 来自函数类 Φ 如(1)中 $y(x)$ 来自线性函数类

设函数类 Φ 的基函数为 $\varphi_i(x)(i = 0, 1, \dots, n)$ 一般要求 $n \leq m$

也称 Φ 是由 $\varphi_i(x)(i = 0, 1, \dots, n)$ 生成的函数集,即

$$\Phi = \text{span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)\}$$

$$S(x) = \sum_{j=0}^n c_j \varphi_j(x) \in \Phi$$

仍然定义平方误差

$$\|\delta\|_2^2 = \sum_{i=0}^m \delta_i^2 = \sum_{i=0}^m (S(x_i) - y_i)^2$$

我们选取的度量标准是

在函数类 Φ 中选取一个函数 $S^*(x)$

$$S^*(x) = \sum_{j=0}^n c_j^* \varphi_j(x) \quad \text{-----}(2)$$

$$= c_0^* \varphi_0(x) + c_1^* \varphi_1(x) + \cdots + c_n^* \varphi_n(x)$$

$$\|\delta^*\|_2^2 = \sum_{i=0}^m (S^*(x_i) - y_i)^2$$

$$= \min_{S(x) \in \Phi} \|\delta\|_2^2 = \min_{S(x) \in \Phi} \sum_{i=0}^m (S(x_i) - y_i)^2 \quad \text{-----}(3)$$

其中 $S(x) = \sum_{j=0}^m c_j \varphi_j(x)$ 为 Φ 中的任意函数

称满足条件(3)的求函数 $S^*(x) = \sum_{j=0}^n c_j^* \varphi_j(x)$ 的方法为

数据拟合的最小二乘法

$$S^*(x) = \sum_{j=0}^n c_j^* \varphi_j(x) \text{ 为 } \underline{\text{最小二乘解}}$$

$$S(x) = \sum_{j=0}^n c_j \varphi_j(x) \text{ 为 } \underline{\text{拟合函数}}, c_j (j = 0, 1, \dots, n) \text{ 为 } \underline{\text{拟合系数}}$$

$\|\delta^*\|_2^2$ 称为最小二乘解的平方误差

在确定了拟合函数 $S(x)$ 后, 如何求拟合系数 $c_j (j = 0, 1, \dots, n)$

使得 $S^*(x) = \sum_{j=0}^n c_j^* \varphi_j(x)$ 满足拟合条件(3)呢?

二、法方程组

由
$$S(x) = \sum_{j=0}^n c_j \varphi_j(x)$$

可知
$$\|\delta\|_2^2 = \sum_{i=0}^m (\boxed{S(x_i)} - y_i)^2 = \sum_{i=0}^m (\boxed{\sum_{j=0}^n c_j \varphi_j(x_i)} - y_i)^2$$

为拟合系数 $c_j (j = 0, 1, \dots, n)$ 的函数

因此可假设

$$\psi(c_0, c_1, \dots, c_n) = \sum_{i=0}^m (\sum_{j=0}^n c_j \varphi_j(x_i) - y_i)^2$$

二次函数

因此求最小二乘解转化为

求 $\psi(c_0, c_1, \dots, c_n)$ 的最小值(极小值)点 $c_0^*, c_1^*, \dots, c_n^*$ 的问题

由多元函数取极值的必要条件

$$\frac{\partial \psi(c_0, c_1, \dots, c_n)}{\partial c_k} = 0 \quad k = 0, 1, \dots, n$$

得

$$\frac{\partial \psi}{\partial c_k} = \sum_{i=0}^m [2(\sum_{j=0}^n c_j \varphi_j(x_i) - y_i) \varphi_k(x_i)] = 0$$

即

$$\sum_{i=0}^m [\sum_{j=0}^n c_j \varphi_j(x_i) \varphi_k(x_i) - y_i \varphi_k(x_i)] = 0$$

$$\sum_{i=0}^m \sum_{j=0}^n c_j \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=0}^m y_i \varphi_k(x_i)$$

$$\sum_{i=0}^m \sum_{j=0}^n c_j \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=0}^m y_i \varphi_k(x_i)$$

$$\sum_{j=0}^n \left[\sum_{i=0}^m \varphi_j(x_i) \varphi_k(x_i) \right] c_j = \sum_{i=0}^m y_i \varphi_k(x_i)$$

$$k = 0, 1, \dots, n \quad \text{-----}(4)$$

即

$$\begin{aligned} & c_0 \sum_{i=0}^m \varphi_0(x_i) \varphi_k(x_i) + c_1 \sum_{i=0}^m \varphi_1(x_i) \varphi_k(x_i) + \dots + c_n \sum_{i=0}^m \varphi_n(x_i) \varphi_k(x_i) \\ &= \sum_{i=0}^m y_i \varphi_k(x_i) \end{aligned} \quad k = 0, 1, \dots, n$$

显然(4)是一个关于 $c_0, c_1, \dots, c_n$ 的 $n+1$ 元线性方程组

引入记号 $\varphi_r = (\varphi_r(x_0), \varphi_r(x_1), \dots, \varphi_r(x_m))$

$$f = (y_0, y_1, \dots, y_m)$$

定义离散形式的内积

$$(\varphi_k, \varphi_j) = \sum_{i=0}^m \varphi_k(x_i) \varphi_j(x_i) \quad \text{-----}(5)$$

$$(\varphi_k, f) = \sum_{i=0}^m \varphi_k(x_i) y_i \quad \text{-----}(6)$$

由于内积满足交换律 $(\varphi_k, \varphi_j) = (\varphi_j, \varphi_k)$

方程组(4)便可化为

$$c_0(\varphi_k, \varphi_0) + c_1(\varphi_k, \varphi_1) + \cdots + c_n(\varphi_k, \varphi_n) = (\varphi_k, f) \\ k = 0, 1, \cdots, n \quad \text{-----}(7)$$

这是一个系数为 (φ_k, φ_j) , 常数项为 (φ_k, f) 的线性方程组

将其表示成矩阵形式

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} (\varphi_0, f) \\ (\varphi_1, f) \\ \vdots \\ (\varphi_n, f) \end{pmatrix} \quad \text{-----}(8)$$

称(8)式为函数序列 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$
在点 $x_0, x_1, \dots, x_m$ 上的法方程组或正规方程组

并且其系数矩阵是离散Gram矩阵

所以法方程组的系数矩阵非奇异,即

$$\det[(\varphi_i, \varphi_j))_{n \times n}] \neq 0$$

根据Cramer法则,法方程组有唯一解

$$c_0 = c_0^*, c_1 = c_1^*, \dots, c_n = c_n^*$$

即
$$\psi(c_0^*, c_1^*, \dots, c_n^*) = \sum_{i=0}^m \left(\sum_{j=0}^n c_j^* \varphi_j(x_i) - y_i \right)^2$$

是
$$\psi(c_0, c_1, \dots, c_n) = \sum_{i=0}^m \left(\sum_{j=0}^n c_j \varphi_j(x_i) - y_i \right)^2$$
 的最小值

所以
$$\sum_{i=0}^m \left(\sum_{j=0}^n c_j^* \varphi_j(x_i) - y_i \right)^2 = \min_{S(x) \in \Phi} \sum_{i=0}^m \left(\sum_{j=0}^n c_j \varphi_j(x_i) - y_i \right)^2$$

即
$$\sum_{i=0}^m (S^*(x_i) - y_i)^2 = \min_{S(x) \in \Phi} \sum_{i=0}^m (S(x_i) - y_i)^2$$

$$\|\delta^*\|_2^2 = \min_{S(x) \in \Phi} \|\delta\|_2^2$$

因此
$$S^*(x) = \sum_{j=0}^n c_j^* \varphi_j(x) \text{ 为最小二乘解}$$

平方逼近误差

$$\|\delta^*\|_2^2 = \sum_{i=0}^m (S^*(x_i) - y_i)^2 = (f, f) - \sum_{j=0}^n c_j^* (f, \varphi_j)$$

若使用多项式 $S(x) = P_n(x)$ 作为 $(x_i, y_i) (i = 0, 1, \dots, m)$ 的拟合函数

拟合函数 $S(x) = P_n(x)$ 的基函数为

$$\varphi_0(x) = 1, \quad \varphi_1(x) = x, \quad \dots, \varphi_k(x) = x^k, \dots, \varphi_n(x) = x^n$$

基函数之间的内积为

$$(\varphi_k, \varphi_j) = \sum_{i=0}^m \varphi_k(x_i) \varphi_j(x_i) = \sum_{i=0}^m x_i^k x_i^j = \sum_{i=0}^m x_i^{k+j}$$

$$(\varphi_k, f) = \sum_{i=0}^m \varphi_k(x_i) y_i = \sum_{i=0}^m x_i^k y_i$$

例1. [回到本节开始的实例](#)，从散点图可以看出
纤维强度和拉伸倍数之间近似与线性关系
故可选取线性函数

$$y(x) = c_0 + c_1 x$$

为拟合函数，其基函数为

$$\varphi_0(x) = 1 \quad \varphi_1(x) = x$$

建立法方程组

根据内积公式，可得

$$(\varphi_0, \varphi_0) = 24 \quad (\varphi_0, \varphi_1) = 127.5 \quad (\varphi_1, \varphi_1) = 829.61$$

$$(\varphi_0, f) = 113.1 \quad (\varphi_1, f) = 731.6$$

法方程组为


$$\begin{pmatrix} 24 & 127.5 \\ 127.5 & 829.61 \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \end{pmatrix} = \begin{pmatrix} 113.1 \\ 731.6 \end{pmatrix}$$

解得 $c_0 = 0.1505$ $c_1 = 0.8587$

$y^*(x) = 0.1505 + 0.8587x$ 即为所求的最小二乘解

平方误差为 $\|\delta^*\|_2^2 = 5.6615$

拟合曲线与散点
的关系如右图:



例2. 求拟合下列数据的最小二乘解

$x = .24 \quad .65 \quad .95 \quad 1.24 \quad 1.73 \quad 2.01 \quad 2.23 \quad 2.52 \quad 2.77 \quad 2.99$
 $y = .23 \quad -.26 \quad -1.10 \quad -.45 \quad .27 \quad .10 \quad -.29 \quad .24 \quad .56 \quad 1$

解: 从数据的散点图可以看出

y 与 x 之间具有三角函数关系 $\cos x$


y 与 x 之间还具有指数函数关系 e^x

y 与 x 之间还具有对数函数关系 $\ln x$

因此假设拟合函数与基函数分别为

$$S(x) = a \ln x + b \cos x + c e^x$$

$$\varphi_0(x) = \ln x \quad \varphi_1(x) = \cos x \quad \varphi_2(x) = e^x$$



通过计算,得法方程组的系数矩阵及常数项矩阵为

$$\begin{pmatrix} 6.7941 & -5.3475 & 63.2589 \\ -5.3475 & 5.1084 & -49.0086 \\ 63.2589 & -49.0086 & 1002.5 \end{pmatrix} \begin{pmatrix} 1.6163 \\ -2.3827 \\ 26.7728 \end{pmatrix}$$

解得
$$\begin{pmatrix} a \\ b \\ c \end{pmatrix} = \begin{pmatrix} -1.0410 \\ -1.2613 \\ 0.030735 \end{pmatrix}$$

y 关于 x 的最小二乘解是

$$S^*(x) = -1.0410 \ln x - 1.2613 \cos x + 0.030735 e^x$$

拟合的平方误差为

[图象如图](#)

$$\begin{aligned} \|\delta^*\|_2^2 &= \sum_{i=0}^m (S^*(x_i) - y_i)^2 \\ &= \sum_{i=0}^m (-1.0410 \ln x_i - 1.2613 \cos x_i + 0.030735 e^{x_i} - y_i)^2 \\ &= 0.92557 \end{aligned}$$

例3. 在某化学反应里,测得生成物浓度 $y\%$ 与时间 t 的数据如下, 试建立 y 关于 t 的经验公式

$t=1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16$
 $y=4.00, 6.40, 8.00, 8.80, 9.22, 9.50, 9.70, 9.86, 10.00,$
 $10.20, 10.32, 10.42, 10.50, 10.55, 10.58, 10.60$

解: 画出时间 t 与浓度 y 的散点图

具有图示的图形的曲线很多, 本题特提供两种形式

指数函数形式 $y = ae^{b/t}$ $\ln y = \ln a + b \frac{1}{t}$

双曲线形式 $y = \frac{t}{at + b}$ $\frac{1}{y} = a + b \frac{1}{t}$

其中 a, b 都是待定系数

(1).指数函数形式 $y = ae^{b/t}$

两边取对数,得

$$\ln y = \ln a + b \frac{1}{t}$$

设 $y' = \ln y, t' = \frac{1}{t}, a' = \ln a$

得 $y' = a' + bt'$

即为拟合函数

基函数为 $\varphi_0(t') = 1, \quad \varphi_1(t') = t'$

解法方程组得 $a' = 2.427, b = -1.0567 \rightarrow a = 11.325$

最小二乘解为 $y = 11.325e^{-1.0567/t}$

平方误差为 $\|\delta_1^*\|_2^2 = 0.11631$

(2). 双曲线形式 $y = \frac{t}{at + b}$

$$\frac{1}{y} = a + b \frac{1}{t}$$

用最小二乘法得


$$a = 0.080174 \quad b = 0.16272$$

即
$$y = \frac{t}{0.080174 t + 0.16272}$$

平方误差为
$$\|\delta_2^*\|_2^2 = 1.5621$$

无论从图形还是从平方误差考虑

在本例中指数函数拟合比双曲线拟合要好



三、加权最小二乘法

对于一组给定的数据点 $(x_i, y_i)(i = 0, 1, \dots, m)$

各点的重要性可能是不一样的

在拟合的数据点 $(x_i, y_i)(i = 0, 1, \dots, m)$ 中

假设 ω_i 表示数据点 (x_i, y_i) 的重度 $k = 0, 1, \dots, m$

重度: 即权重或者密度，统称为权系数

定义加权平方误差为 $\|\delta\|_2^2 = \sum_{i=0}^m \omega_i \delta_i^2 = \sum_{i=0}^m \omega_i (y(x_i) - y_i)^2$ -----(9)

设拟合函数 $S(x)$ 来自函数类 Φ

函数类 Φ 的基函数为 $\varphi_i(x)(i = 0, 1, \dots, n)$

$$\Phi = \text{span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)\}$$

$$S(x) = c_0\varphi_0(x) + c_1\varphi_1(x) + \dots + c_n\varphi_n(x)$$

$c_j(j = 0, 1, \dots, n)$ 为拟合系数

拟合的目标仍然为找一组 $c_j^*(j = 0, 1, \dots, n)$

使得

$$\begin{aligned}\|\delta^*\|_2^2 &= \sum_{i=0}^m \omega_i (S^*(x_i) - y_i)^2 \\ &= \min_{S(x) \in \Phi} \|\delta\|_2^2 = \min_{S(x) \in \Phi} \sum_{i=0}^m \omega_i (S(x_i) - y_i)^2\end{aligned}$$

$$\text{求 } \psi(c_0, c_1, \dots, c_n) = \sum_{i=0}^m \omega_i \left(\sum_{j=0}^n c_j \varphi_j(x_i) - y_i \right)^2$$

的最小值(极小值)点 $c_0^*, c_1^*, \dots, c_n^*$ 的问题

由多元函数取极值的必要条件

$$\frac{\partial \psi(c_0, c_1, \dots, c_n)}{\partial c_k} = 0 \quad k = 0, 1, \dots, n$$

得

$$\frac{\partial \psi}{\partial c_k} = \sum_{i=0}^m [\omega_i 2 \left(\sum_{j=0}^n c_j \varphi_j(x_i) - y_i \right) \varphi_k(x_i)] = 0$$

即

$$\sum_{i=0}^m [\omega_i \sum_{j=0}^n c_j \varphi_j(x_i) \varphi_k(x_i) - \omega_i y_i \varphi_k(x_i)] = 0$$

$$\sum_{i=0}^m \omega_i \sum_{j=0}^n c_j \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=0}^m \omega_i y_i \varphi_k(x_i)$$

$$\sum_{i=0}^m \omega_i \sum_{j=0}^n c_j \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=0}^m \omega_i y_i \varphi_k(x_i)$$

$$\sum_{j=0}^n \left[\sum_{i=0}^m \omega_i \varphi_j(x_i) \varphi_k(x_i) \right] c_j = \sum_{i=0}^m \omega_i y_i \varphi_k(x_i)$$

$$k = 0, 1, \dots, n$$

-----**(10)**

显然(10)是一个关于 $c_0, c_1, \dots, c_n$ 的 $n+1$ 元线性方程组

同样引入记号 $\varphi_r = (\varphi_r(x_0), \varphi_r(x_1), \dots, \varphi_r(x_m))$

$$f = (y_0, y_1, \dots, y_m)$$

定义加权内积

$$(\varphi_k, \varphi_j) = \sum_{i=0}^m \omega_i \varphi_k(x_i) \varphi_j(x_i) \quad (\varphi_k, f) = \sum_{i=0}^m \omega_i \varphi_k(x_i) y_i$$

方程组(10)式化为

$$c_0(\varphi_k, \varphi_0) + c_1(\varphi_k, \varphi_1) + \cdots + c_n(\varphi_k, \varphi_n) = (\varphi_k, f) \\ k = 0, 1, \dots, n \quad \text{-----}(11)$$

矩阵形式(法方程组)为

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} (\varphi_0, f) \\ (\varphi_1, f) \\ \vdots \\ (\varphi_n, f) \end{pmatrix} \quad \text{---}(12)$$

平方误差为 $\|\delta^*\|_2^2 = \sum_{i=0}^m \omega_i (S^*(x_i) - y_i)^2$

作为特殊情形,用多项式作拟合函数的法方程组为

$$\begin{pmatrix} \sum_{i=0}^m \omega_i & \sum_{i=0}^m \omega_i x_i & \cdots & \sum_{i=0}^m \omega_i x_i^n \\ \sum_{i=0}^m \omega_i x_i & \sum_{i=0}^m \omega_i x_i^2 & \cdots & \sum_{i=0}^m \omega_i x_i^{n+1} \\ \vdots & \vdots & & \vdots \\ \sum_{i=0}^m \omega_i x_i^n & \sum_{i=0}^m \omega_i x_i^{n+1} & \cdots & \sum_{i=0}^m \omega_i x_i^{2n} \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c \end{pmatrix} = \begin{pmatrix} \sum_{i=0}^m \omega_i y_i \\ \sum_{i=0}^m \omega_i x_i y_i \\ \vdots \\ \sum_{i=0}^m \omega_i x_i^n y_i \end{pmatrix}$$

-----**(13)**

四、用正交多项式作最小二乘拟合

对于一组给定的数据点 $(x_i, y_i)(i = 0, 1, \dots, m)$

若拟合函数 $S(x)$ 的基函数(基底)选为

$$\varphi_0(x) = P_0(x), \quad \varphi_1(x) = P_1(x), \quad \dots, \quad \varphi_n(x) = P_n(x)$$

且 $P_0(x), P_1(x), \dots, P_n(x)$ 为正交多项式

$$\text{即} \quad (P_k, P_j) = \sum_{i=1}^m \omega_i P_k(x_i) P_j(x_i) = \begin{cases} 0 & k \neq j \\ A_k & k = j \end{cases} \quad \text{-----}(14)$$

其中 $A_k > 0$

正交多项式如何选取呢

若 $P_0(x), P_1(x), \dots, P_n(x)$ 线性无关

且任意 k 次多项式均可由 $P_0(x), P_1(x), \dots, P_k(x)$ 线性表示

选取正交多项式 $P_0(x), P_1(x), \dots, P_n(x)$ 时令其首项系数均为1

考虑 $k+1$ 次多项式 $xP_k(x)$

显然其可由 $P_0(x), P_1(x), \dots, P_{k+1}(x)$ 线性表示

即存在系数 $\beta_0, \beta_1, \dots, \beta_{k-1}, \alpha_k, 1$

使得

$$xP_k(x) = \sum_{j=0}^{k-1} \beta_j \cdot P_j(x) + \alpha_k P_k(x) + P_{k+1}(x)$$

$$xP_k(x) = \sum_{j=0}^{k-1} \beta_j \cdot P_j(x) + \alpha_k P_k(x) + P_{k+1}(x)$$

由 $(xP_k, P_s) = (\sum_{j=0}^{k-1} \beta_j \cdot P_j(x) + \alpha_k P_k(x) + P_{k+1}(x), P_s(x))$

可知 $(xP_k, P_s) = \beta_s (P_s, P_s) \quad (s < k)$

$$(xP_k, P_k) = \alpha_k (P_k, P_k)$$

因此

$$\alpha_k = \frac{(xP_k, P_k)}{(P_k, P_k)}$$

$$\beta_s = \frac{(xP_k, P_s)}{(P_s, P_s)}$$

而

$$\beta_s = \frac{(xP_k, P_s)}{(P_s, P_s)} = \frac{(P_k, xP_s)}{(P_s, P_s)}$$

$xP_s(x)$ 为 $s+1$ 次多项式

可由正交多项式组 $\{P_j(x)\}_0^{s+1}$ 线性表示

当 $s+1 < k$ 时 即 $s < k-1$ 时 $(P_k, xP_s) = 0$

因此

$$\beta_s = \begin{cases} 0 & s < k-1 \\ \frac{(P_k, xP_{k-1})}{(P_{k-1}, P_{k-1})} & s = k-1 \end{cases}$$

$$\frac{(P_k, xP_{k-1})}{(P_{k-1}, P_{k-1})} = \frac{(P_k, P_k)}{(P_{k-1}, P_{k-1})}$$

由
$$xP_k(x) = \sum_{j=0}^{k-1} \beta_j \cdot P_j(x) + \alpha_k P_k(x) + P_{k+1}(x)$$

可知
$$\begin{aligned} P_{k+1}(x) &= xP_k(x) - \sum_{j=0}^{k-1} \beta_j \cdot P_j(x) - \alpha_k P_k(x) \\ &= (x - \alpha_k)P_k(x) - \beta_{k-1}P_{k-1}(x) \end{aligned}$$

最后可得正交多项式选取的方法:

$$P_0(x) = 1$$

$$P_1(x) = x - \alpha_0 \quad \alpha_0 = \frac{1}{m+1} \sum_{i=0}^m \omega_i x_i \triangleq \frac{(xP_0, P_0)}{(P_0, P_0)}$$

$$P_{k+1}(x) = (x - \alpha_k)P_k(x) - \beta_{k-1}P_{k-1}(x) \quad \text{-----}(15)$$

$$\alpha_k = \frac{(xP_k, P_k)}{(P_k, P_k)} \quad \beta_{k-1} = \frac{(P_k, P_k)}{(P_{k-1}, P_{k-1})} \quad i = 1, 2, \dots, n$$

对于一组给定的带权 ω_i 的数据点 $(x_i, y_i)(i = 0, 1, \dots, m)$

选择正交多项式 $P_0(x), P_1(x), \dots, P_n(x)$ 作拟合

$$S(x) = c_0 P_0(x) + c_1 P_1(x) + \dots + c_n P_n(x)$$

使得

$$\begin{aligned} \|\delta^*\|_2^2 &= \sum_{i=0}^m \omega_i (S^*(x_i) - y_i)^2 \\ &= \min_{S(x) \in \Phi} \|\delta\|_2^2 = \min_{S(x) \in \Phi} \sum_{i=0}^m \omega_i (S(x_i) - y_i)^2 \end{aligned}$$

由正交多项式的性质,法方程组

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} (\varphi_0, f) \\ (\varphi_1, f) \\ \vdots \\ (\varphi_n, f) \end{pmatrix}$$

可化为

$$\begin{pmatrix} (P_0, P_0) & 0 & \cdots & 0 \\ 0 & (P_1, P_1) & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & (P_n, P_n) \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} (P_0, f) \\ (P_1, f) \\ \vdots \\ (P_n, f) \end{pmatrix}$$

即 $(P_k, P_k)c_k = (P_k, f) \quad i = 0, 1, 2, \dots, n \quad \text{-----}(16)$

得 $c_k^* = \frac{(P_k, f)}{(P_k, P_k)} \quad \text{-----}(17)$

即 $S^*(x) = c_0^* P_0(x) + c_1^* P_1(x) + \cdots + c_n^* P_n(x)$

为利用正交多项式的最小二乘解

平方误差为

$$\begin{aligned}\|\delta^*\|_2^2 &= \sum_{i=0}^m \omega_i (S^*(x_i) - y_i)^2 \\&= (S^*(x) - f, S^*(x) - f) \\&= (S^*, S^*) - 2(S^*, f) + (f, f) \\&= \sum_{k=0}^n c_k^2 (P_k, P_k) - 2 \sum_{k=0}^n c_k (P_k, f) + (f, f) \\&= \sum_{k=0}^n c_k^2 (P_k, P_k) - 2 \sum_{k=0}^n c_k (P_k, P_k) + (f, f) \\&= (f, f) - \sum_{k=0}^n c_k^2 (P_k, P_k)\end{aligned}$$

例4. 给定数据点 (x_i, y_i) 及权重 ω_i 如下


x_i	0	0.5	0.6	0.7	0.8	0.9	1.0
y_i	1	1.75	1.96	2.19	2.44	2.71	3.0
ω_i	1	1	1	1	1	1	1

是用最小二乘法求拟合这组数据的多项式

解: 从散点图可知

数据和二次多项式拟合较好

因此选用二次多项式作
这组数据的拟合函数



设拟合函数 $S(x) = c_0 P_0(x) + c_1 P_1(x) + c_2 P_2(x)$

$P_0(x), P_1(x), P_2(x)$ 为基函数

取

$$P_0(x) = 1$$

$$c_0 = \frac{(P_0, f)}{(P_0, P_0)} = \frac{15.05}{7} = 2.15$$

$$c_0 = \frac{(xP_0, P_0)}{(P_0, P_0)} = \frac{4.5}{7}$$

$$P_1(x) = x - c_0 = x - 0.642857$$

$$c_1 = \frac{(P_1, f)}{(P_1, P_1)} = \frac{1.300000}{0.657143} = 1.978260$$

$$\alpha_1 = \frac{(xP_1, P_1)}{(P_1, P_1)} = \frac{0.220408}{0.657143} = 0.335403$$

$$\beta_0 = \frac{(P_1, P_1)}{(P_0, P_0)} = \frac{0.657143}{7} = 0.093878$$

$$P_2(x) = (x - \alpha_1)P_1(x) - \beta_0 P_0(x)$$

$$= (x - 0.335403)(x - 0.642857) - 0.093878$$

$$= x^2 - 0.978260x + 0.121738$$

$$c_2 = \frac{(P_2, f)}{(P_2, P_2)} = \frac{0.068656}{0.068660} = 0.999942$$

因此拟合多项式为

$$\begin{aligned} S(x) &= c_0 P_0(x) + c_1 P_1(x) + c_2 P_2(x) \\ &= 0.999942x^2 + 1.000057x + 0.999993 \end{aligned}$$

平方误差为

$$\begin{aligned} \|\delta^*\|_2^2 &= (f, f) - \sum_{k=0}^n c_k^2 (P_k, P_k) \\ &= 2.313856 \times 10^{-10} \end{aligned}$$